

Projeto de Disciplina de Deep Learning com TensorFlow

Classificação de Câncer de Mama

1. MEMBROS DO GRUPO

- Mateus Teixeira Ramos da Silva - GitHub
 - Fabio Ferreira Figueiredo - GitHub
 - Felipe Szczpanski - GitHub
 - Lauro Barbosa - GitHub
 - Thiago Vinícius - GitHub
 - Wilson Melo - GitHub
-

2. PROBLEMA DE NEGÓCIO

2.1 Contexto e Relevância

O câncer de mama é uma das principais causas de morte por câncer em mulheres mundialmente. A detecção precoce é fundamental para aumentar as chances de cura e reduzir a mortalidade. Atualmente, o diagnóstico depende da análise manual de características morfológicas de células, um processo que pode ser:

- **Subjetivo:** Dependente da experiência do patologista
- **Demorado:** Análise manual consome tempo valioso
- **Custoso:** Requer especialistas altamente qualificados
- **Variável:** Pode haver inconsistências entre diferentes profissionais

2.2 Tipo de Problema

CLASSIFICAÇÃO BINÁRIA SUPERVISIONADA

Por que Classificação? - Temos uma variável target categórica (diagnosis) com duas classes distintas: - **B (Benigno):** Tumor não canceroso - **M (Maligno):** Tumor canceroso - O objetivo é prever a categoria/classe do tumor baseado nas características morfológicas

Por que Supervisionada? - Possuímos dados rotulados (ground truth) com diagnósticos confirmados - O modelo aprenderá padrões a partir de exemplos conhecidos - Podemos avaliar a performance comparando previsões com diagnósticos reais

Alternativas Consideradas e Rejeitadas: - **Regressão:** Rejeitada pois não queremos prever valores contínuos - **Agrupamento (Clustering):** Rejeitada

pois temos labels conhecidos - **Classificação Multiclasse**: Não aplicável pois temos apenas duas classes

3. BASE DE DADOS

3.1 Origem e Credibilidade

Fonte: Kaggle - Breast Cancer Dataset

Origem Original: Wisconsin Diagnostic Breast Cancer (WDBC) Database - Criado por: Dr. William H. Wolberg, University of Wisconsin - Amplamente utilizado na literatura científica - Benchmark padrão para algoritmos de classificação médica

3.2 Tamanho da Amostra

- **569 amostras** (pacientes)
- **33 colunas** (32 features + 1 target)
- **Sem dados faltantes** nas colunas relevantes
- **1 coluna nula** (Unnamed: 32) que será removida

Justificativa do Tamanho: - Tamanho adequado para redes neurais simples - Suficiente para validação cruzada robusta - Permite divisão treino/validação/teste sem overfitting - Comparável a outros estudos na área médica

3.3 Colunas / Features / Atributos

Estrutura dos Dados: Cada feature é calculada para: 1. **Mean** (média): Valor médio da característica 2. **SE** (standard error): Erro padrão da característica

3. **Worst** (pior valor): Maior valor (mais extremo) da característica

10 Características Morfológicas Base:

1. **radius**: Distância média do centro aos pontos do perímetro
2. **texture**: Desvio padrão dos valores de escala de cinza
3. **perimeter**: Perímetro do núcleo celular
4. **area**: Área do núcleo celular
5. **smoothness**: Variação local nos comprimentos dos raios
6. **compactness**: $(\text{perímetro}^2 / \text{área}) - 1.0$
7. **concavity**: Severidade das porções côncavas do contorno
8. **concave_points**: Número de porções côncavas do contorno
9. **symmetry**: Simetria do núcleo celular
10. **fractal_dimension**: “Aproximação da linha costeira” - 1

Total: 30 features numéricas (10 características $\times$ 3 estatísticas)

4. ANÁLISE EXPLORATÓRIA

4.1 Distribuição da Variável Target (Y)

Distribuição das Classes: - **Benigno (B):** 357 casos (62.7%) - **Maligno (M):** 212 casos (37.3%)

Análise: - **Desbalanceamento moderado:** Razão aproximada 1.7:1 - **Não crítico:** Não requer técnicas especiais de balanceamento - **Representativo:** Ambas as classes têm amostras suficientes - **Realista:** Reflete a distribuição real na população

Implicações para o Modelo: - Usar métricas balanceadas (F1-score, AUC-ROC) - Considerar precision e recall para ambas as classes - Stratified sampling na divisão treino/teste

4.2 Distribuição das Features (X)

Características Observadas:

1. **Escalas Diferentes:**
 - Area: 143.5 - 2501.0
 - Smoothness: 0.05 - 0.16
 - **Necessidade:** Normalização obrigatória
2. **Distribuições Variadas:**
 - Algumas features seguem distribuição normal
 - Outras apresentam assimetria (skewness)
 - **Solução:** StandardScaler para padronização
3. **Outliers Presentes:**
 - Identificados através de boxplots
 - **Estratégia:** Manter (podem ser informativos clinicamente)

4.3 Atributos Mais e Menos Relevantes

MAIS RELEVANTES (Baseado em Correlação e Importância Clínica):

1. **concave_points_worst:** Alta correlação com malignidade
 - **Justificativa:** Tumores malignos tendem a ter contornos mais irregulares
2. **perimeter_worst:** Forte indicador de malignidade
 - **Justificativa:** Tumores maiores frequentemente são malignos
3. **concavity_worst:** Relacionado à forma irregular
 - **Justificativa:** Malignidade associada a bordas côncavas
4. **radius_worst:** Tamanho máximo do tumor
 - **Justificativa:** Tumores malignos tendem a crescer mais
5. **area_worst:** Área máxima do núcleo

- **Justificativa:** Correlacionado com agressividade

MENOS RELEVANTES:

1. **fractal_dimension_mean:** Baixa correlação
 - **Justificativa:** Medida complexa, menos interpretável clinicamente
2. **symmetry_se:** Variabilidade baixa
 - **Justificativa:** Erro padrão da simetria pouco discriminativo
3. **smoothness_se:** Pouco poder discriminativo
 - **Justificativa:** Variação da suavidade menos informativa

Metodologia de Seleção: - Análise de correlação com target - Matriz de correlação entre features - Conhecimento médico especializado - Testes estatísticos (ANOVA, Chi-quadrado)

4.4 Representação Escolhida

ESTRATÉGIA: Usar **TODAS** as **30 features numéricas**

Justificativas:

1. **Redes Neurais são Robustas:** Podem lidar com alta dimensionalidade
2. **Regularização:** Dropout e L2 previnem overfitting
3. **Informação Complementar:** Features “menos relevantes” podem ter valor em combinação
4. **Benchmark:** Permite comparação com literatura existente
5. **Custo Computacional Baixo:** 30 features é gerenciável

Pré-processamento Aplicado: - Remoção da coluna ‘id’ (identificador único)
 - Remoção da coluna ‘Unnamed: 32’ (valores nulos) - Codificação da target: B=0, M=1 - StandardScaler nas features numéricas

5. TREINAMENTO

5.1 Topologia Escolhida

ARQUITETURA: Rede Neural Feedforward Densa

Camada de Entrada: 30 neurônios (features)

↓

Camada Oculta 1: [2 a 10] neuronios (considerando o melhor modelo) + ReLU + Dropout(0.3)

↓

Camada Oculta 2: [2 a 10]/2 neuronios (considerando o melhor modelo) + ReLU + Dropout(0.3)

↓

Camada de Saída: 1 neurônio + Sigmoid

5.2 Justificativas da Arquitetura

Por que Feedforward? - Dados tabulares não têm dependência sequencial - Estrutura mais simples e interpretável - Adequada para classificação binária - Menor risco de overfitting

Por que 2 Camadas Ocultas? - **1 camada:** Pode ser insuficiente para padrões complexos - **2 camadas:** Balanceio entre capacidade e simplicidade - **3+ camadas:** Risco de overfitting com dataset pequeno

Por que ReLU? - **Não saturação:** Evita vanishing gradient - **Computacionalmente eficiente:** Operação simples - **Esparsidade:** Alguns neurônios ficam inativos - **Estado da arte:** Padrão atual em deep learning

Por que Sigmoid na saída? - **Classificação binária:** Output entre 0 e 1 - **Interpretabilidade:** Pode ser vista como probabilidade - **Compatibilidade:** Funciona bem com binary_crossentropy

5.3 Referências e Benchmarks

Literatura Científica:

1. Street, W.N., Wolberg, W.H. and Mangasarian, O.L. (1993)
 - “Nuclear feature extraction for breast tumor diagnosis”
 - **Resultado:** 97.5% de acurácia com linear programming
 - **Nossa meta:** Superar com redes neurais
2. Wolberg, W.H., Street, W.N. and Mangasarian, O.L. (1995)
 - “Machine learning techniques to diagnose breast cancer”
 - **Comparação:** Múltiplos algoritmos no mesmo dataset
 - **Baseline:** Nosso ponto de referência
3. **Estudos Recentes com Deep Learning:**
 - CNNs: 95-98% acurácia
 - MLPs: 93-96% acurácia
 - **Nossa expectativa:** 94-97% acurácia

Modelos de Comparação no Projeto:

1. **Dummy Classifier:** Baseline simples (classe majoritária)
2. **Logistic Regression:** Baseline linear clássico
3. **Keras Padrão:** Rede neural sem otimização
4. **Keras Optimized (Grid Search):** Rede neural otimizada

Métricas de Avaliação: - **Acurácia:** Métrica principal - **Precision:** Importante para reduzir falsos positivos - **Recall:** Crítico para não perder casos malignos - **F1-Score:** Balanceio entre precision e recall - **AUC-ROC:** Avaliação independente do threshold

Melhor modelo: Modelo comparado com a baseline: Keras optimized (Grid Search): score: 0.9524 recall. Aproximadamente 5% superior ao Baseline

Convergência do treinamento e seleção dos hiperparâmetros: Conforme o melhor modelo selecionado pela busca em grid Epoch 11: early stopping
Melhores parâmetros: {'model__dropout_rate': 0.3, 'model__learning_rate': 0.01, 'model__neurons': 7};

A partir da epoch 11 se notou uma estabilização na métrica “val_recall” (selecionada como critério de parada);

O valor de dropout foi de 0.3 (30% dos neurônios desligados a cada iteração);

Taxa de aprendizado de 0.01, o que apresentou um crescimento equilibrado de aprendizado ao modelo, não tão alto que atingisse um underfitting ou não tão baixo que atingisse um overfitting;

A quantidade de neurônios selecionados foi de 7 (2 para a segunda camada), o que se mostrou bastante eficiente;

5.4 Estratégia de Validação

Validação Cruzada Estratificada (3-fold) - Mantém proporção das classes em cada fold - Reduz variância das estimativas - Uso eficiente dos dados limitados

Grid Search para Hiperparâmetros: - Learning rate: [0.001, 0.01, 0.1] - Neurons: [2, 5, 7] - Dropout rate: [0.1, 0.2, 0.3] - Epochs: 200 com Early stopping e patience - Otimizador: Adam

Figura de mérito obtida - Foi selecionado a métrica Recall pois como se trata de uma classificação binária de detecção de câncer (maligno x benigno) a detecção de um falso positivo é muito mais grave do que um falso negativo (neste caso, por exemplo, uma pessoa ser diagnosticada com câncer e não ter).

6 Deployment

- Deployment no Streamlit modelo salvo no arquivo .PKL